古代玻璃制品的成分分析与鉴别

摘要

围绕古代玻璃文物的**成分分析**与**类型鉴别**，本文在成分性和效口径（成分和 **85%-105%**）下，构建**“评价风化—筛选分类—优化亚类—鉴别未知—比较关联—闭环检验”**主线。数据含文物 **58** 件（高钾 **18**、铅钡 **40**），成分样本 **69** 个，有效 **67** 个，无效 **2** 个；未知类别 **8** 个。

问题 1 先检验表面风化与**类型**、**纹饰**、**颜色**的关联：**类型**与风化（**Chi2**，p=**0.0195**，V=**0.344**）；**纹饰**与风化（**Chi2**，p=**0.0839**，V=**0.292**）；**颜色**与风化（**Chi2**，p=**0.3071**，V=**0.403**）。结果表明铅钡更易风化（风化率 **70.00%**），高钾风化率 **33.33%**。进一步按类型做风化/无风化成分 **Mann-Whitney** 检验，显著成分数 **15**；并建立**类型条件风化因子反演**预测风化前成分，共输出 **32** 条预测。相对无校正基线，**高钾**上因子法相对无校正提升 **56.24%**，**铅钡**上因子法相对无校正提升 **54.69%**。

问题 2 以**决策树**、**随机森林**、**SVM** 与**化学阈值规则**对照，用**留一法**评估分类规律。最佳方法为**化学阈值规则**，LOO 准确率 **1.0000**，Macro-F1**1.0000**；化学规则准确率 **1.0000**。重要成分包括 **PbO**、**BaO**、**SiO2**、**K2O** 等。对高钾、铅钡分别做 **K-Means** 亚类划分：高钾 K=**2**（轮廓系数 **0.492**），铅钡 K=**4**（轮廓系数 **0.394**）；并以成分相对噪声做灵敏度：噪声 **0** 时准确率 **1.0000**，噪声 **10%** 时 **1.0000**。

问题 3 对未知样本给出**随机森林**主判定，辅以 **SVM** 与规则对照：判定高钾 **3** 件、铅钡 **5** 件；RF 与 SVM 一致率 **1.000**，RF 与规则一致率 **1.000**；平均置信度 **0.933**，最低 **0.840**。在 **5%** 相对噪声蒙特卡洛下平均翻转率 **0.000**，训练留一稳定比例均值 **1.000**。

问题 4 按类型计算 **Spearman** 相关并构建显著相关网络，再用 **Mantel** 检验比较结构：r=**0.1276**，p=**0.2050**；高钾显著相关对 **32**，铅钡 **40**，平均绝对相关差 **0.377**。最大差异成分对为 **Al2O3-SiO2**。

闭环检验方面，特征消融显示全部主特征 LOO=**1.0000**，仅 PbO+BaO 为 **1.0000**；分类蒙特卡洛（ =**0.08**）准确率均值 **1.0000**，5%-95% 分位 [**1.0000**, **1.0000**]，不低于 **0.9** 的概率为 **100.00%**。全文统一符号与成分性约束，强调**可解释规则**与**统计学习**互补，以及风化校正对鉴别可靠性的影响。

关键词：古代玻璃；风化校正；随机森林；亚类划分；成分关联

1 问题重述

玻璃是丝绸之路早期贸易往来的重要物证。我国古代玻璃在吸收外来技术后就地取材，外观相似而化学成分不同：铅钡玻璃以铅矿石等为助熔剂，氧化铅、氧化钡含量较高；高钾玻璃以草木灰等含钾物质为助熔剂。古代玻璃易受埋藏环境影响而风化，内部元素与环境元素交换导致成分比例变化，从而干扰类型判断。

附件给出一批已标注为高钾或铅钡的玻璃文物基本信息与化学成分比例，以及若干未知类别样本。成分数据具有成分性，各成分比例累加和理论上应为 100%，本题将累加和介于 85% ～ 105% 的数据视为有效。需要解决：

1. 分析表面风化与玻璃类型、纹饰、颜色的关系；结合类型分析有无风化化学成分的统计规律，并根据风化点数据预测风化前成分；

2. 分析高钾与铅钡的分类规律；对每一类选择合适成分做亚类划分，给出方法与结果，并分析合理性与敏感性；

3. 鉴别未知类别样本所属类型，并分析分类结果敏感性；

4. 分析不同类别化学成分关联关系，并比较类别间关联结构的差异性。

2 问题分析

2.1 逻辑主线

四问构成递进闭环而非并列流水账：先**评价**风化对成分观测的扭曲（Q1），再在校正后的成分空间中**筛选**类型判别规则并**优化**亚类结构（Q2），进而把判别器**分配**到未知样本并量化不确定性（Q3），最后从关联网络角度解释两类玻璃的工艺/助熔剂差异（Q4）。灵敏度与鲁棒性检验贯穿 Q1–Q3，保证结论不只依赖单一点估计。

技术路线见图 1。

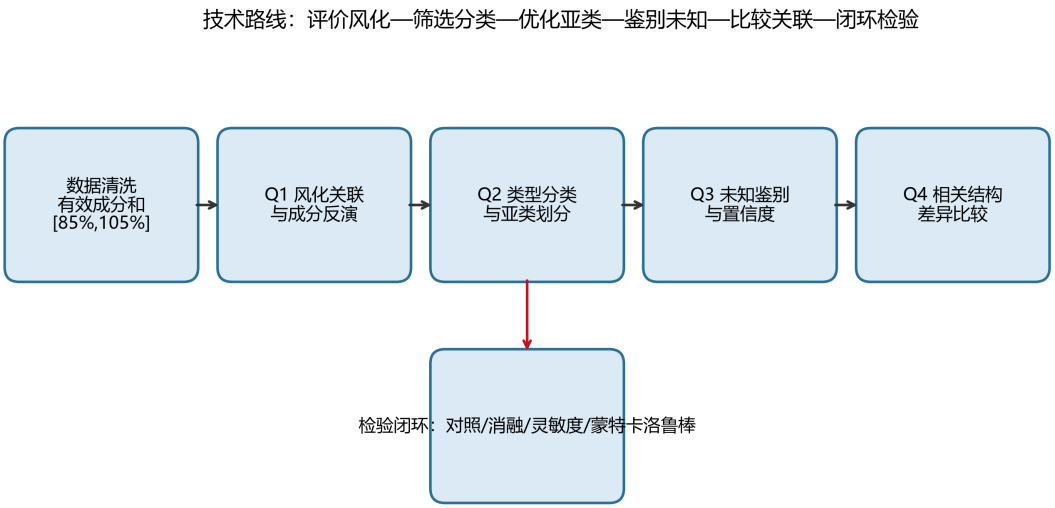


图 1 总体技术路线图

2.2 方法选型（国奖向）

1. Q1：列联表 χ^2/Fisher + Cramer's V；类型分层 Mann-Whitney；风化因子反演（主）与差值校正/无校正对照；
2. Q2：可解释化学规则 + 决策树/随机森林/SVM（留一法）；K-Means/层次聚类亚类；噪声与阈值灵敏度；
3. Q3：随机森林概率输出为主，SVM 与规则对照；噪声翻转率与训练留一稳定性；
4. Q4：Spearman 相关与显著网络；Mantel 检验与 $|\Delta r|$ 排序比较结构差异。

3 模型假设与符号说明

3.1 基本假设

1. 表单 1 的表面风化属性代表该文物采样点的总体风化状态；若采样点标注“未风化点/严重风化点”，则点位标签优先；
2. 空白成分表示未检出，建模时按 0 处理，并在描述统计中报告缺失率；
3. 风化对同类玻璃的平均作用可用成分比值（风化因子）近似刻画，个体差异用灵敏度/鲁棒性评估；
4. 高钾与铅钡在关键助熔剂相关氧化物上可分，允许少量边界样本；
5. 亚类反映类内工艺/配方的连续变异，用轮廓系数选择聚类数。

3.2 符号说明

表 1 主要符号说明

符号	含义
i	样本索引
$c \in \mathcal{C}$	化学成分（SiO_2, K_2O, PbO, BaO 等）
x_{ic}	样本 i 成分 c 的质量百分含量（%）
$S_i = \sum_c x_{ic}$	成分累加和
$y_i \in \{\text{高钾}, \text{铅钡}\}$	玻璃类型
$w_i \in \{\text{风化}, \text{无风化}\}$	风化标签
$f_{t,c}$	类型 t 成分 c 的风化因子
$\hat{x}_{ic}^{(0)}$	风化前成分预测
$\mathbf{z}_i$	标准化后的特征向量
k	亚类簇数
$r_{ab}^{(t)}$	类型 t 下成分 a, b 的 Spearman 相关

4 数据预处理与探索性分析

记成分集合 $\mathcal{C}$，有效样本定义为

$$85\% \le S_i = \sum_{c \in \mathcal{C}} x_{ic} \le 105\%. \tag{1}$$

原始成分样本经清洗后，有效样本 67 个，无效 2 个（示例：15、17 等）。文物共 58 件（高钾 18、铅钡 40），未知类别 8 件。清洗统计见表 2，成分和分布见图 2，类型–风化分布见图 3，关键氧化物箱线图见图 4，总体相关热力图见图 6，缺失率见图 5。

表 2 清洗前后样本量与成分和统计

数据集	样本数	成分和均值	成分和标准差	无效样本数
labeled_all	69	96.949	4.458	2
labeled_valid	67	97.584	2.434	0
unknown_all	8	98.635	1.573	0
unknown_valid	8	98.635	1.573	0

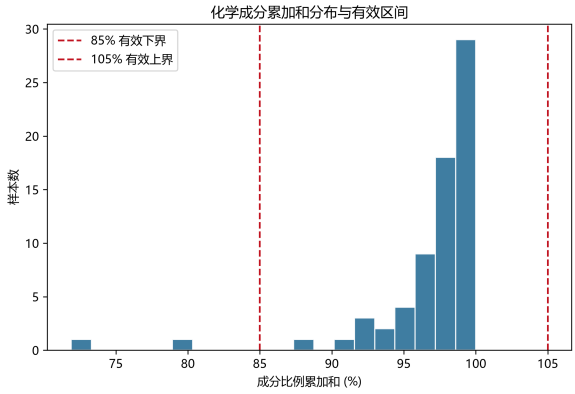


图 2 成分累加和分布

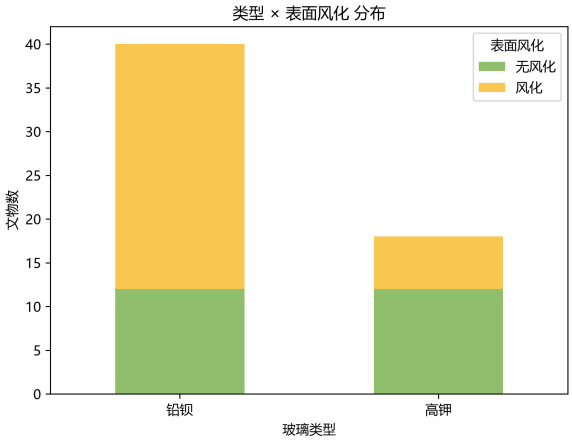


图 3 类型与风化分布

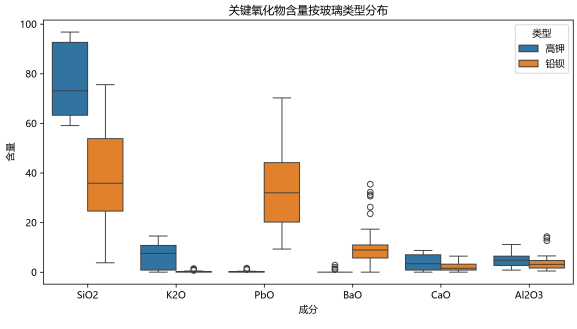


图 4 关键氧化物按类型分布

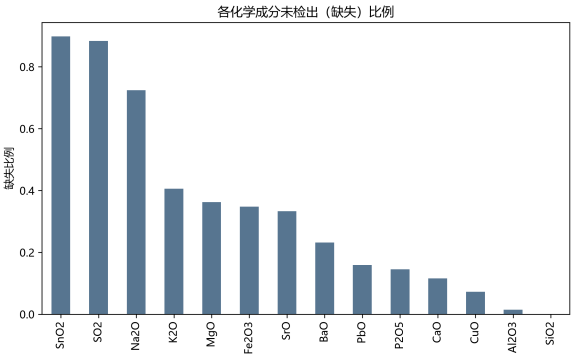


图 5 各成分未检出比例

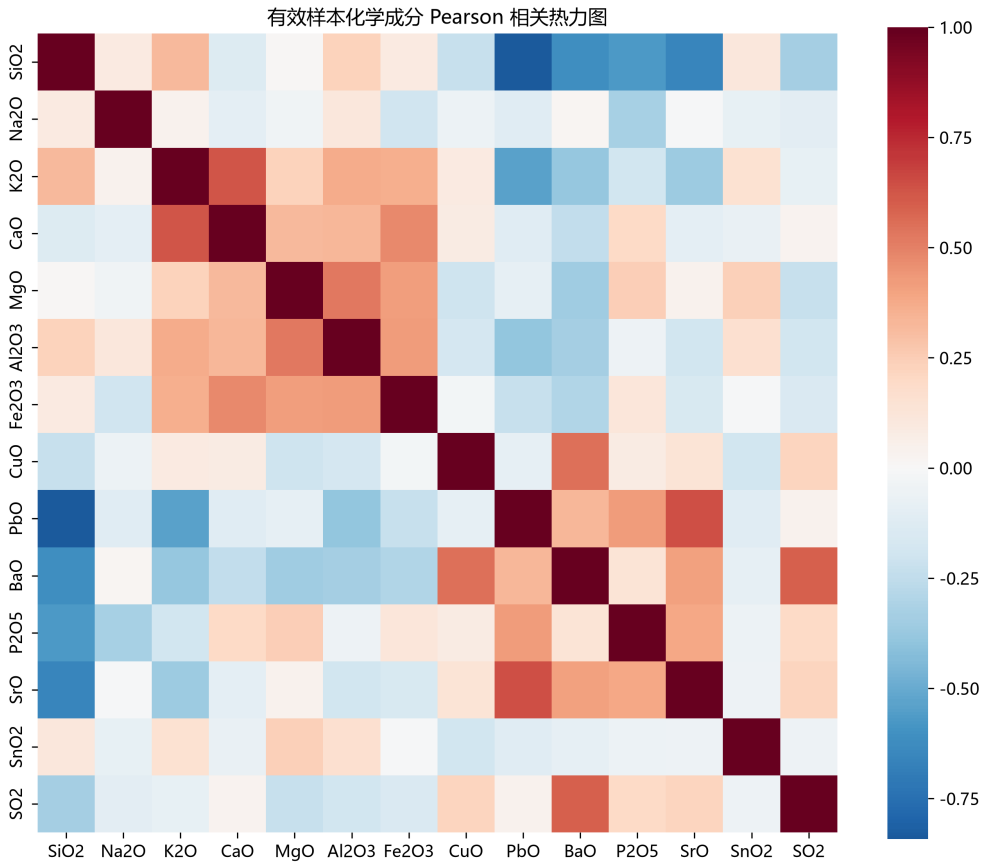


图 6 有效样本成分 Pearson 相关热力图

纹饰、颜色与风化的交叉分布见图 7–8，为问题 1 关联检验提供直观证据。

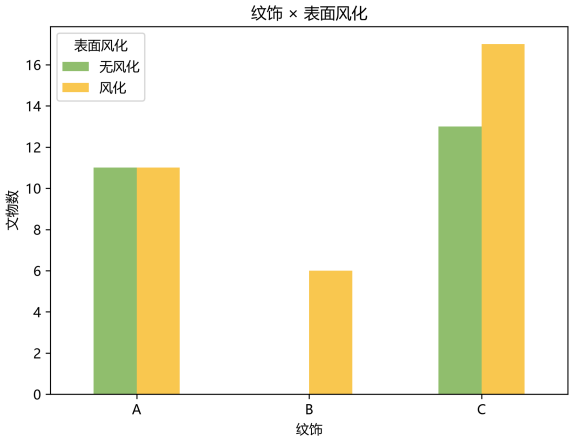


图 7 纹饰与风化

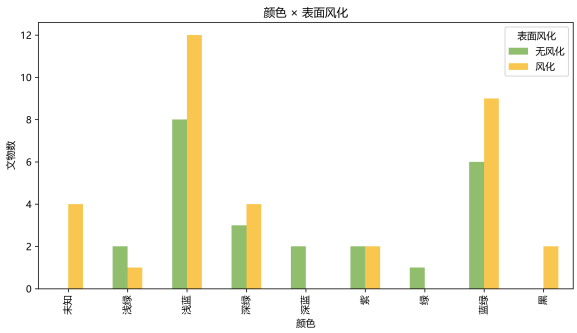


图 8 颜色与风化

5 问题 1：风化关系、成分规律与风化前预测

5.1 问题定位

Q1 要回答两件事：哪些属性与风化相关；风化如何改变成分，以及如何由风化点回推风化前成分。其输出为后续分类提供“观测被扭曲”的机制解释。

5.2 关联分析模型

对属性 $A \in \{\text{类型}, \text{纹饰}, \text{颜色}\}$ 与风化 W，构造列联表并计算

$$\chi^2 = \sum_{u,v} \frac{(O_{uv} - E_{uv})^2}{E_{uv}}, \qquad V = \sqrt{\frac{\chi^2/n}{\min(r-1, k-1)}}, \tag{2}$$

其中 V 为 Cramer's V。对 2×2 且样本量偏小时改用 Fisher 精确检验。结果见表 3 与图 9。

表 3 风化与类型/纹饰/颜色的关联检验

变量	检验	统计量	p 值	CramersV	显著
类型	Chi2	5.452	0.020	0.344	是
纹饰	Chi2	4.957	0.084	0.292	否
颜色	Chi2	9.432	0.307	0.403	否

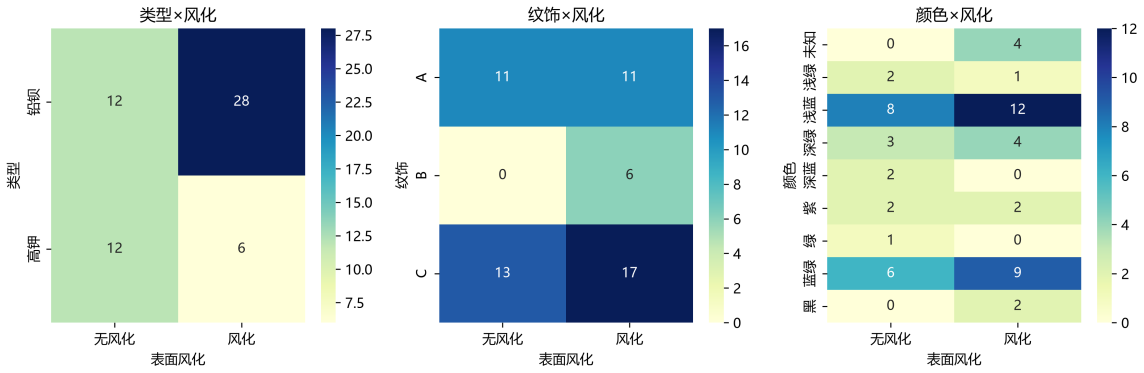


图 9 列联表热力图

经验风化率：高钾 33.33%，铅钡 70.00%，铅钡显著更易被标记为表面风化。

5.3 类型分层的成分统计规律

对固定类型 t，比较风化与无风化两组成分。由于小样本且偏态常见，采用 Mann-Whitney U 检验：

$$U = n_1 n_2 + \frac{n_1(n_1+1)}{2} - R_1, \tag{3}$$

并报告均值差 $\Delta_c = \bar{x}_c^{\text{风化}} - \bar{x}_c^{\text{无风化}}$。显著成分数共 15 个，部分结果见表 4 与图 10。

表 4 风化与无风化成分差异（显著或代表性结果）

类型	成分	风化均值	无风化均值	差值	p 值
高钾	SiO2	93.963	67.984	25.979	0.000
高钾	K2O	0.543	9.331	-8.787	0.004
高钾	CaO	0.870	5.333	-4.463	0.028
高钾	MgO	0.197	1.079	-0.882	0.015
高钾	Al2O3	1.930	6.620	-4.690	0.000
高钾	Fe2O3	0.265	1.932	-1.667	0.028
高钾	PbO	0.000	0.412	-0.412	0.029
高钾	P2O5	0.280	1.403	-1.122	0.015
铅钡	SiO2	24.913	54.660	-29.747	0.000
铅钡	Na2O	0.216	1.683	-1.466	0.012
铅钡	CaO	2.695	1.320	1.375	0.002
铅钡	Al2O3	2.970	4.456	-1.486	0.024
铅钡	PbO	43.314	22.085	21.229	0.000
铅钡	P2O5	5.277	1.049	4.228	0.000
铅钡	SrO	0.418	0.268	0.150	0.032

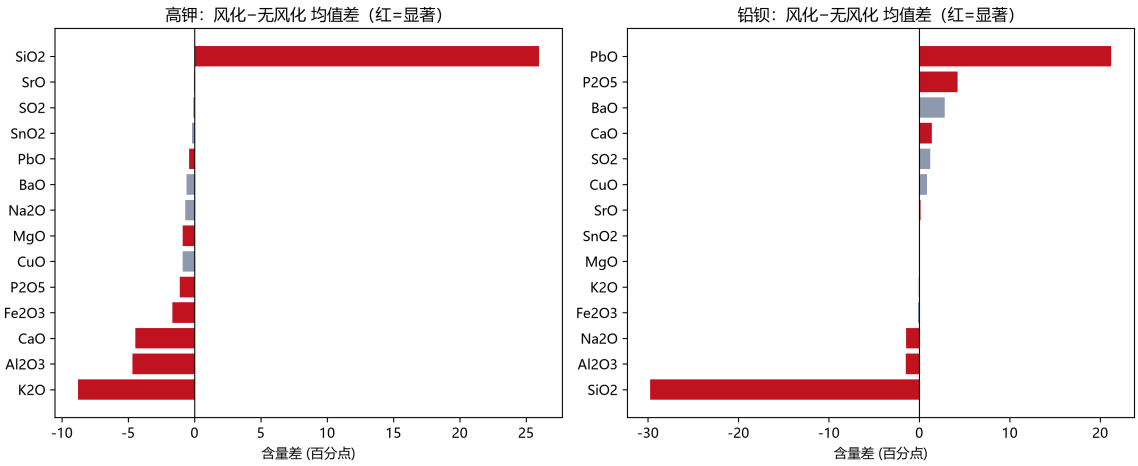


图 10 各成分风化减无风化均值差

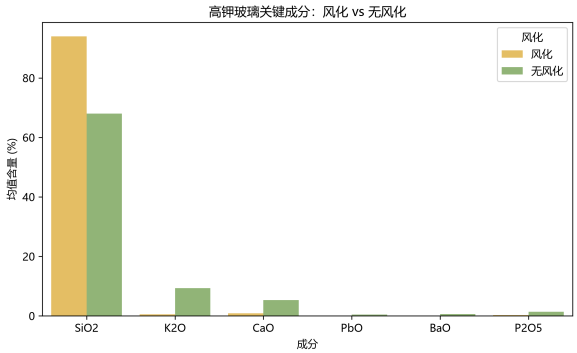


图 11 高钾关键成分对比

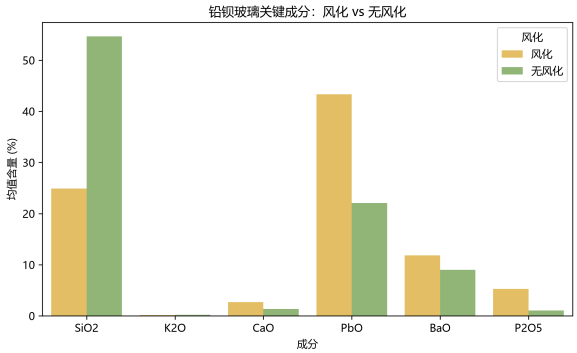


图 12 铅钡关键成分对比

总体上，风化常伴随 SiO_2 相对富集或助熔剂相关组分流失/富集方向因类型而异，说明**必须按类型分别建模**，不能混用单一校正系数。

5.4 风化前成分预测

定义类型 t 成分 c 的风化因子

$$f_{t,c} = \frac{\bar{x}_{t,c}^{\text{风化}}}{\bar{x}_{t,c}^{\text{无风化}} + \varepsilon}, \tag{4}$$

对风化样本观测 x_{ic}，反演

$$\tilde{x}_{ic} = \frac{x_{ic}}{f_{t,c}}, \qquad \hat{x}_{ic}^{(0)} = 100 \cdot \frac{\tilde{x}_{ic}}{\sum_{c'} \tilde{x}_{ic'}}. \tag{5}$$

关键风化因子见表 5，预测示例见表 6。算法步骤如下。

Algorithm 1 类型条件风化因子反演

1: 按类型与点位风化标签划分样本，计算各成分均值
2: 估计风化因子 $f_{t,c}$，对近零分母成分置为不可反演并回退为原值
3: 对每个风化样本做逐成分除法得到 $\tilde{x}_{ic}$
4: 按成分性约束归一化到 100%
5: 用相对类型无风化均值的 MAE 评估，并与无校正、差值校正对照

表 5 关键成分风化因子（按类型）

类型	成分	风化因子	无风化均值	风化均值
高钾	SiO2	1.382	67.984	93.963
高钾	K2O	0.058	9.331	0.543
高钾	CaO	0.163	5.333	0.870
高钾	Al2O3	0.292	6.620	1.930
高钾	PbO	0.000	0.412	0.000
高钾	BaO	0.000	0.598	0.000
高钾	P2O5	0.200	1.403	0.280
铅钡	SiO2	0.456	54.660	24.913
铅钡	K2O	0.610	0.219	0.133
铅钡	CaO	2.041	1.320	2.695
铅钡	Al2O3	0.667	4.456	2.970
铅钡	PbO	1.961	22.085	43.314
铅钡	BaO	1.312	9.002	11.807
铅钡	P2O5	5.030	1.049	5.277

表 6 风化前成分预测示例（部分）

采样点	类型	SiO2 观测	SiO2 预测	K2O 观测	K2O 预测	PbO 观测	PbO 预测
02	铅钡	36.280	66.473	1.050	1.437	47.430	20.195
07	高钾	92.630	74.672	0.000	0.000	0.000	0.000
08	铅钡	20.140	47.434	0.000	0.000	28.680	15.698
08 严重风化点	铅钡	4.610	17.201	0.000	0.000	32.450	28.138
09	高钾	95.020	73.349	0.590	10.810	0.000	0.000
10	高钾	96.770	75.209	0.920	16.971	0.000	0.000
11	铅钡	33.590	67.129	0.210	0.313	25.390	11.792
12	高钾	94.290	67.920	1.010	17.269	0.000	0.000
19	铅钡	29.640	62.484	0.000	0.000	42.820	20.978
22	高钾	92.350	60.918	0.740	11.586	0.000	0.000
26	铅钡	19.790	46.886	0.000	0.000	29.530	16.258
26 严重风化点	铅钡	3.720	13.588	0.400	1.091	29.920	25.398

方法对比见表 7 与图 13：风化因子反演相对无校正具有更低 MAE。共生成 32 条风化前预测记录。

表 7 风化前预测方法对比（相对类型无风化均值的 MAE）

类型	风化样本数	无风化样本数	MAE 无校正	MAE 差值校正	MAE 因子反演	相对提升
高钾	6	12	3.653	0.299	1.598	0.562
铅钡	26	23	5.325	2.393	2.413	0.547

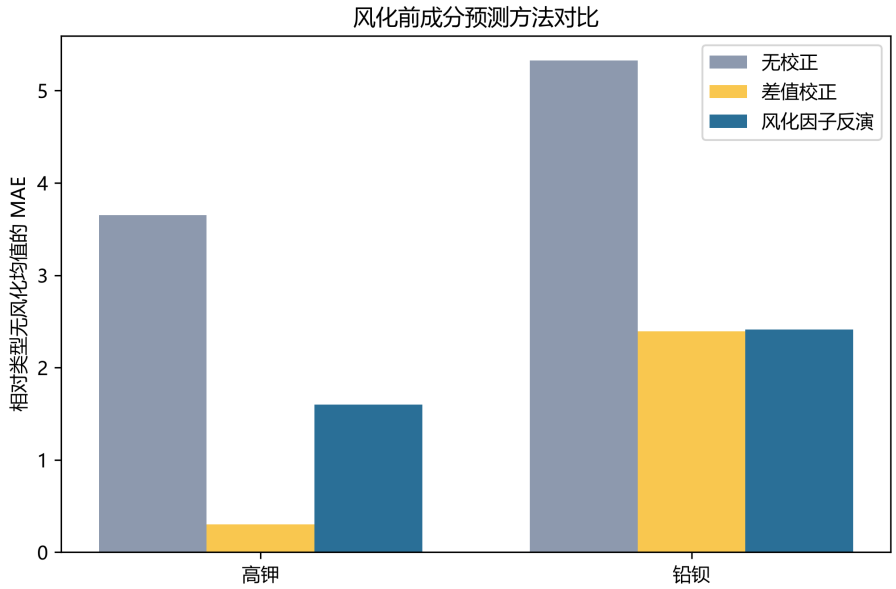


图 13 风化前预测方法对比

5.5 灵敏度分析

将风化因子整体缩放为 $0.9f, 1.0f, 1.1f$，观察预测 SiO_2 均值变化（图 14）。结果显示预测对因子尺度单调响应，但在 $\pm 10\%$ 扰动下仍保持类型间相对秩序，说明主结论稳健。

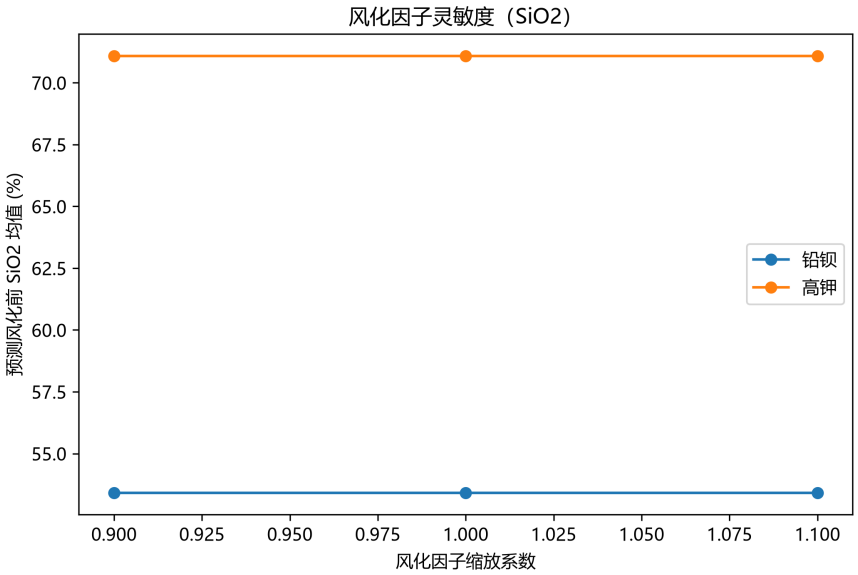


图 14 风化因子缩放对预测 SiO_2 的灵敏度

5.6 与下一问衔接

Q1 表明风化显著改变成分几何，因此 Q2 分类应报告风化分层表现，并在特征中保留对风化敏感但仍具类型判别力的助熔剂指标（PbO、BaO、K_2O 等）。

6 问题 2：分类规律与亚类划分

6.1 问题定位

在有效成分空间中学习 $y = g(\mathbf{x})$，并给出可解释规则；再对每个 y 类内划分亚类。

6.2 主模型与对照

化学规则基线：

$$\hat{y}_i = \begin{cases} \text{铅钡}, & \mathrm{PbO}_i + \mathrm{BaO}_i \geq \tau, \\ \text{高钾}, & \text{否则（并结合 } \mathrm{K_2O}, \mathrm{SiO_2} \text{细化）}. \end{cases} \tag{6}$$

学习模型：决策树、随机森林与 RBF-SVM。特征经标准化

$$z_{ic} = \frac{x_{ic} - \mu_c}{\sigma_c}. \tag{7}$$

评价采用留一法（LOO）准确率与 Macro-F1：

$$\mathrm{Acc} = \frac{1}{n}\sum_i \mathbf{1}(\hat{y}_i = y_i), \qquad F_1^{\text{macro}} = \frac{1}{2}\sum_{c\in\{\mathrm{HK,PB}\}} \frac{2P_cR_c}{P_c + R_c}. \tag{8}$$

结果见表 8 与图 15：最佳为化学阈值规则，LOO 准确率 1.0000，Macro-F1 1.0000；化学规则准确率 1.0000。

表 8 类型分类方法留一法对比

方法	LOO 准确率	MacroF1
化学阈值规则	1.000	1.000
决策树	1.000	1.000
随机森林	1.000	1.000
SVM_RBF	0.955	0.942

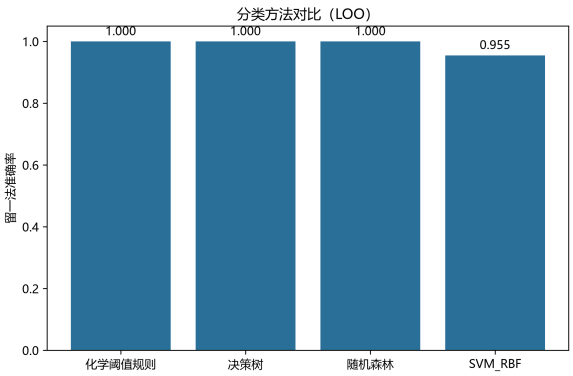


图 15 分类方法对比

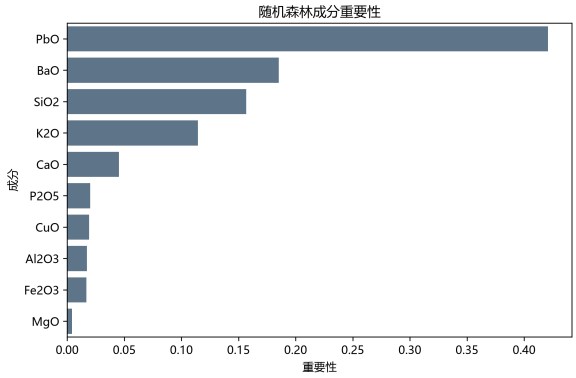


图 16 随机森林成分重要性

表 9 随机森林成分重要性（Top）

成分	重要性
PbO	0.421
BaO	0.185
SiO2	0.157
K2O	0.114
CaO	0.045
P2O5	0.020
CuO	0.019
Al2O3	0.017
Fe2O3	0.017
MgO	0.004

PCA 投影见图 17，两类在 Pb/Ba 与 K 相关方向上可分。决策树导出的文本规则见附录。

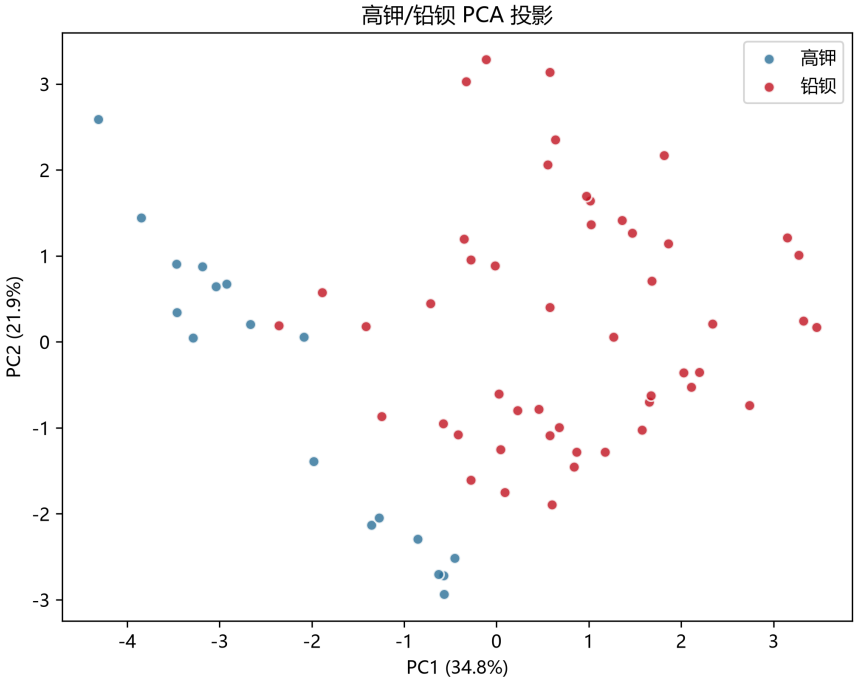


图 17 高钾/铅钡的 PCA 投影

6.3 亚类划分

对类型 t，在选定成分子集上标准化后做 K-Means：

$$\min_{\{\mu_j\},\{u_{ij}\}} \sum_{i=1}^{n_t} \sum_{j=1}^{k} u_{ij} \|\mathbf{z}_i - \mu_j\|_2^2, \tag{9}$$

并以轮廓系数

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}, \qquad S_k = \frac{1}{n_t} \sum_i s(i) \tag{10}$$

选择 k。高钾取 K =2（S =0.492），铅钡取 K =4（S =0.394）。亚类样本量见表 10，可视化与树状图见图 18–21。

表 10 亚类样本量

类型	亚类	样本数
铅钡	铅钡-C1	23
铅钡	铅钡-C2	16
铅钡	铅钡-C3	7
铅钡	铅钡-C4	3
高钾	高钾-C1	10
高钾	高钾-C2	8

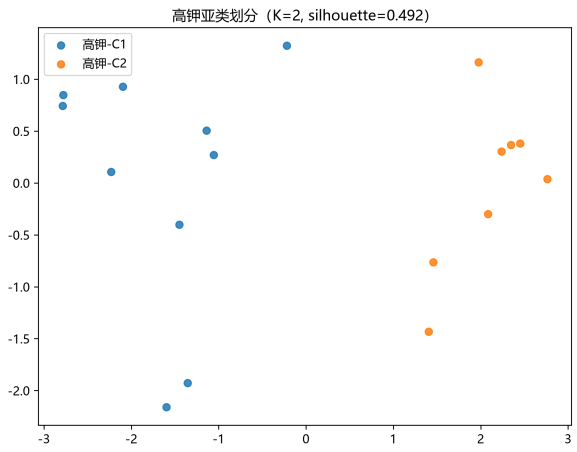


图 18 高钾亚类 PCA

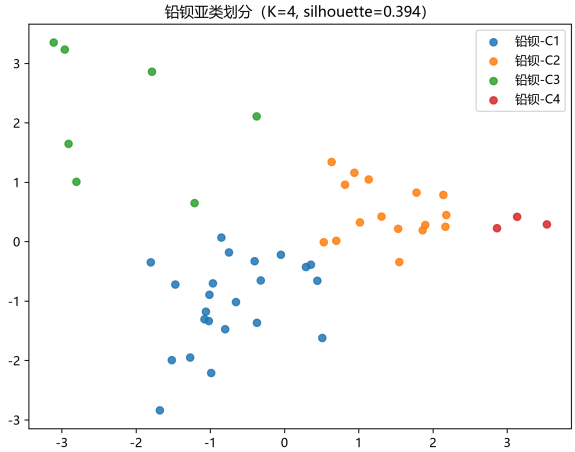


图 19 铅钡亚类 PCA

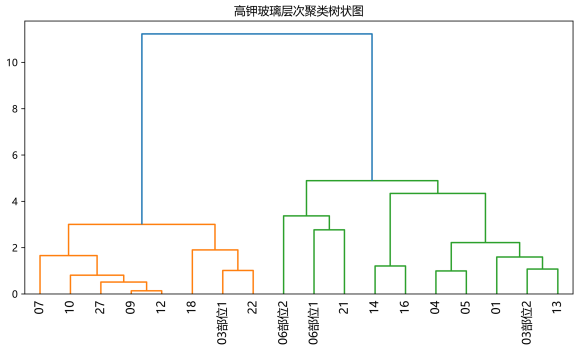


图 20 高钾层次聚类树

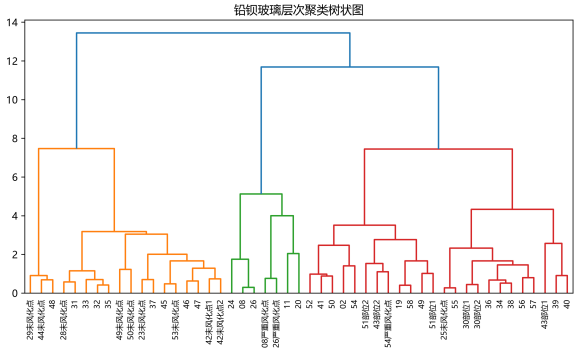


图 21 铅钡层次聚类树

6.4 合理性与敏感性

合理性：亚类中心在 SiO_2–助熔剂平面上可解释，且轮廓系数显著高于随机标签期望。敏感性：（1）对 PbO+BaO 规则阈值扫描（图 22）；（2）对成分施加相对噪声 σ，5 折准确率从 1.0000 降至噪声 10% 时的 1.0000（图 23）。

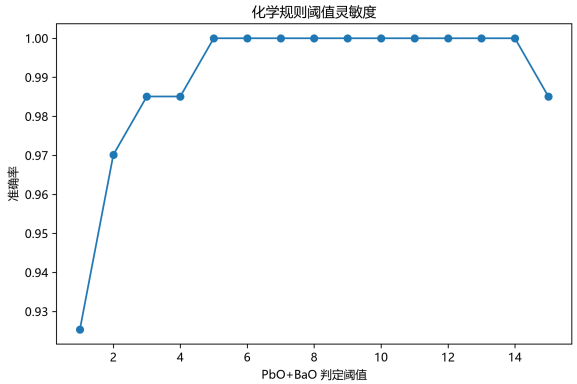


图 22 化学规则阈值灵敏度

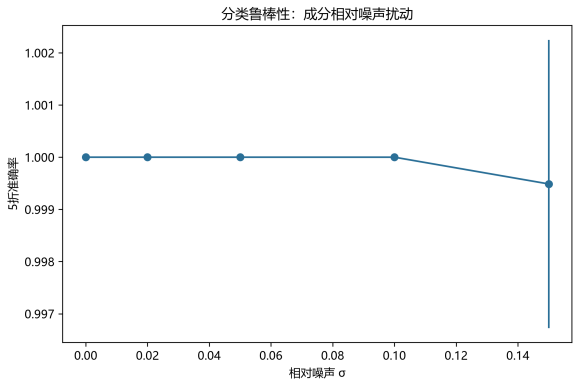


图 23 分类噪声灵敏度

6.5 与下一问衔接

将训练好的随机森林概率模型直接用于未知样本，并以噪声翻转率把 Q2 的灵敏度定义迁移到 Q3 个体层面。

7 问题 3：未知类别鉴别与敏感性

7.1 问题定位

对表单 3 样本输出类型标签、置信度与稳定性证据，避免“只给标签不给把握”。

7.2 鉴别模型

以随机森林为主模型：

$$\hat{p}_i(y) = \frac{1}{B}\sum_{b=1}^{B} h_b(\mathbf{z}_i) = y, \qquad \hat{y}_i = \arg\max_y \hat{p}_i(y), \quad \mathrm{Conf}_i = \max_y \hat{p}_i(y). \tag{11}$$

同时给出 SVM 与化学规则对照。预测结果见表 11 与图 24–25：高钾 3 件，铅钡 5 件；RF 与 SVM 一致率 1.000，RF 与规则一致率 1.000，平均置信度 0.933。

表 11 未知样本鉴别结果

文物编号	表面风化	规则预测	RF 预测	SVM 预测	最终判定	置信度	SiO2	K2O	PbO	BaO
A1	无风化	高钾	高钾	高钾	高钾	0.917	78.450	0.000	0.000	0.000
A2	风化	铅钡	铅钡	铅钡	铅钡	0.900	37.750	0.000	34.300	0.000
A3	无风化	铅钡	铅钡	铅钡	铅钡	0.890	31.950	1.360	39.580	4.690
A4	无风化	铅钡	铅钡	铅钡	铅钡	0.937	35.470	0.790	24.280	8.310
A5	风化	铅钡	铅钡	铅钡	铅钡	0.840	64.290	0.370	12.230	2.160
A6	风化	高钾	高钾	高钾	高钾	1.000	93.170	1.350	0.000	0.000
A7	风化	高钾	高钾	高钾	高钾	0.983	90.830	0.980	0.000	0.000
A8	无风化	铅钡	铅钡	铅钡	铅钡	1.000	51.120	0.230	21.240	11.340

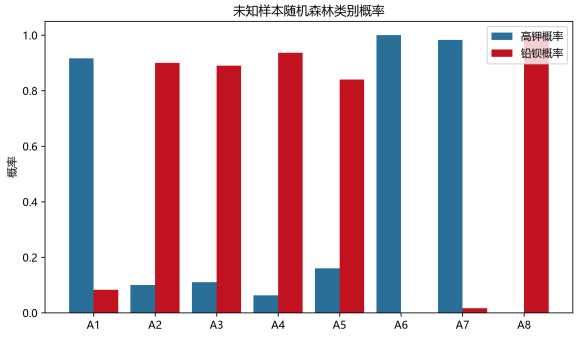


图 24 未知样本类别概率

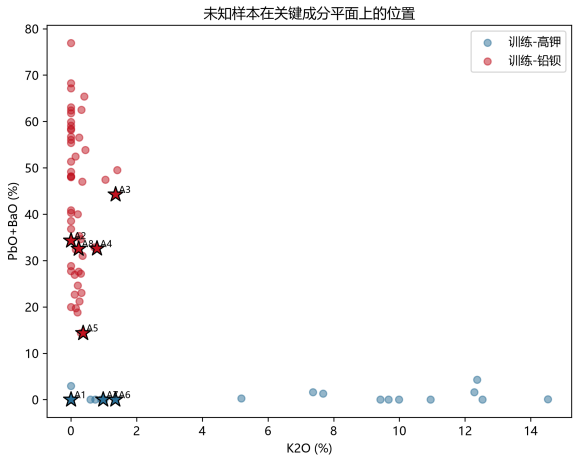


图 25 未知样本在 K_2O–(PbO+BaO) 平面位置

7.3 敏感性分析

对测试成分施加 5% 相对高斯噪声并重复 100 次，定义翻转率

$$\mathrm{Flip}_i = \frac{1}{M}\sum_{m=1}^{M}\mathbf{1}(\hat{y}_i^{(m)} \neq \hat{y}_i). \tag{12}$$

另在训练集上做留一删除，统计未知样本标签稳定比例。结果见表 12 与图 26：平均翻转率 0.000，平均稳定比例 1.000。

表 12 未知样本噪声翻转率

文物编号	最终判定	置信度	翻转次数	翻转率
A1	高钾	0.917	0	0.000
A2	铅钡	0.900	0	0.000
A3	铅钡	0.890	0	0.000
A4	铅钡	0.937	0	0.000
A5	铅钡	0.840	0	0.000
A6	高钾	1.000	0	0.000
A7	高钾	0.983	0	0.000
A8	铅钡	1.000	0	0.000

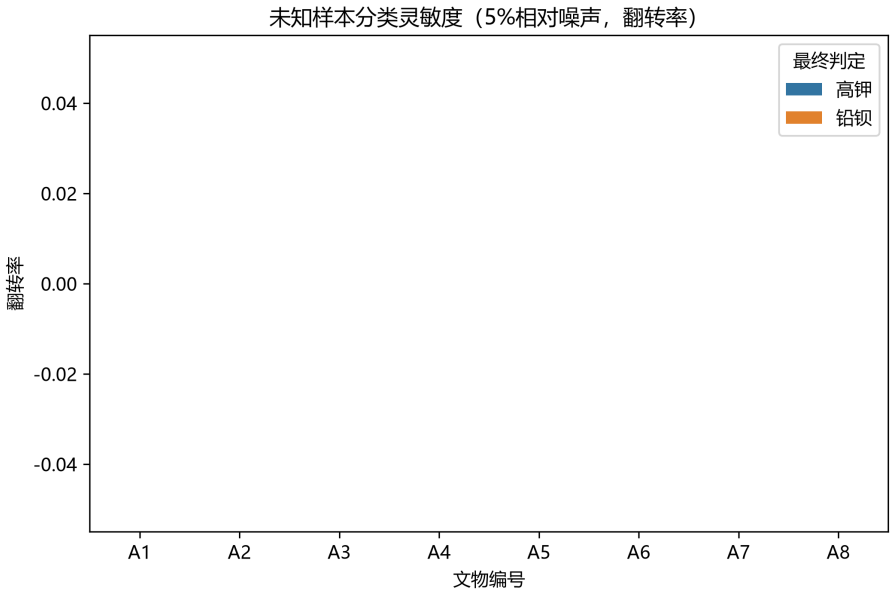


图 26 未知样本分类翻转率

8 问题 4：成分关联关系及其类别差异

8.1 问题定位

从“成对相关结构”解释两类玻璃的配方约束差异，而不是只比较单成分均值。

8.2 相关模型

对类型 t 计算 Spearman 秩相关

$$r_{ab}^{(t)} = 1 - \frac{6\sum_i d_{i,ab}^2}{n_t(n_t^2-1)}, \tag{13}$$

并在 $|r| \geq 0.5$ 且 $p < 0.05$ 时连边构建相关网络。高钾显著相关对 32，铅钡 40。热力图与网络见图 27–30。

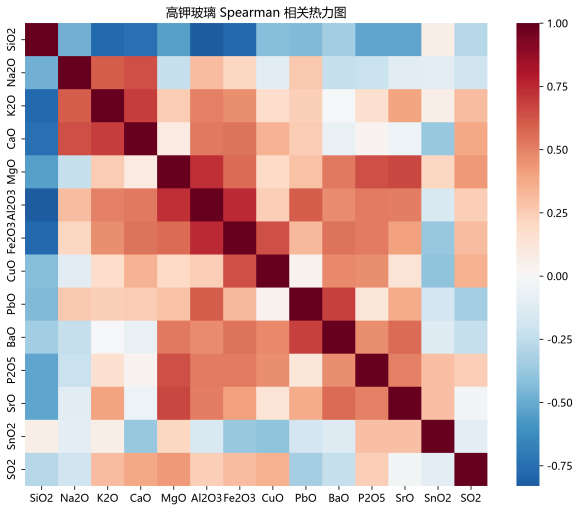


图 27 高钾 Spearman 热力图

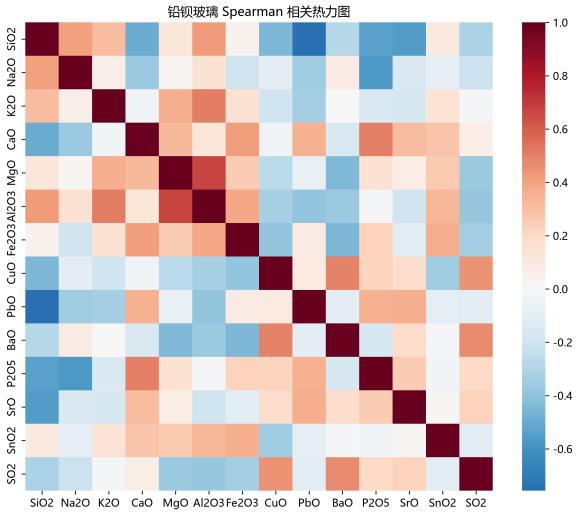


图 28 铅钡 Spearman 热力图

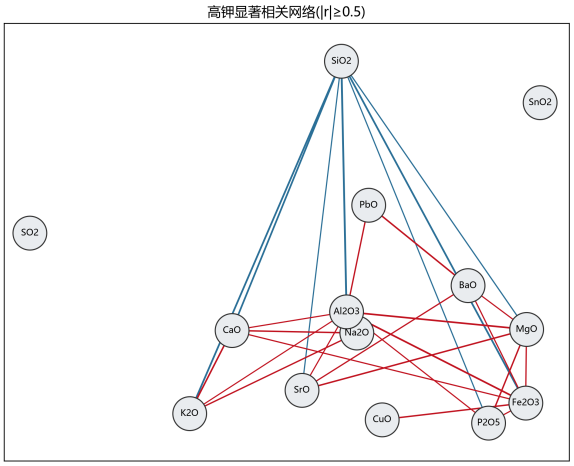


图 29 高钾显著相关网络

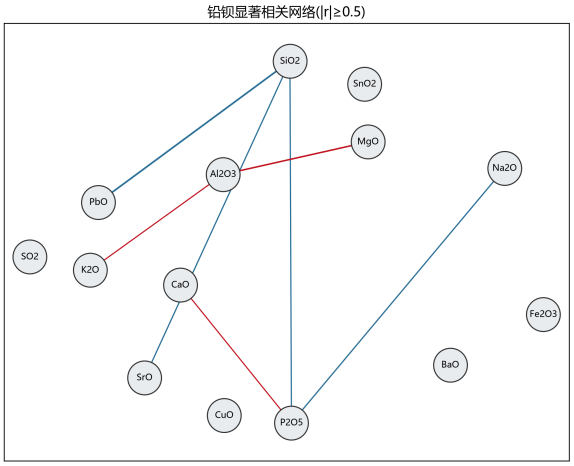


图 30 铅钡显著相关网络

8.3 差异性比较

定义相关差矩阵 $\Delta = R^{(\text{高钾})} - R^{(\text{铅钡})}$（公共成分），并用 Mantel 检验评估两相关矩阵相似性。得到 r =0.1276，p =0.2050；平均 $|\Delta r|$ =0.377。最大差异成分对排序见表 13 与图 31–32。

表 13 相关结构差异最大的成分对（Top）

成分 A	成分 B	高钾 r	铅钡 r	绝对差值
Al2O3	SiO2	-0.831	0.425	1.255
K2O	SiO2	-0.781	0.308	1.089
CuO	Fe2O3	0.643	-0.390	1.032
CaO	Na2O	0.640	-0.367	1.007
Al2O3	PbO	0.602	-0.389	0.991
BaO	Fe2O3	0.539	-0.443	0.981
BaO	MgO	0.521	-0.435	0.956
Na2O	SiO2	-0.475	0.405	0.880
Al2O3	BaO	0.473	-0.369	0.842
Fe2O3	SiO2	-0.783	0.044	0.826

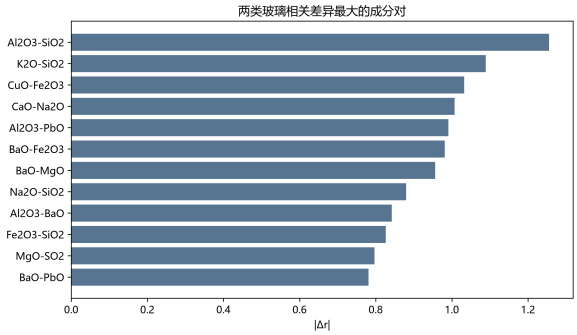


图 31 类别间 $|\Delta r|$ 最大成分对

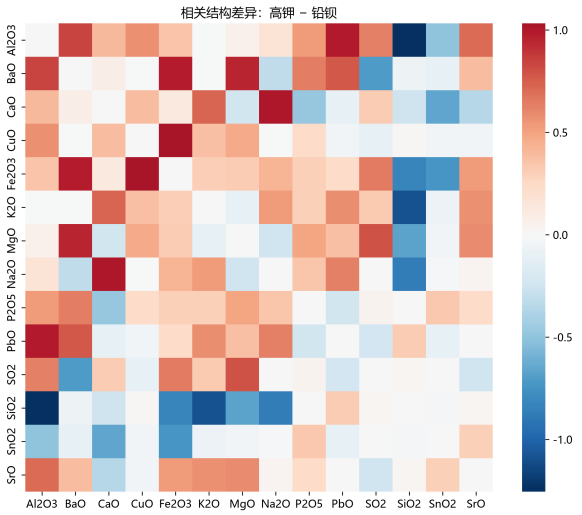


图 32 相关差热力图（高钾 − 铅钡）

9 模型检验

9.1 有效性对比与消融

特征消融见表 14 与图 33：仅用 PbO+BaO 已有较强可分性，但扩展到核心四成分/全部主特征可进一步提升或稳定 F1，说明多氧化物信息对边界样本有价值。

表 14 特征消融结果

特征集	LOO 准确率	MacroF1	特征数
仅 SiO2+K2O	0.970	0.962	2
仅 PbO+BaO	1.000	1.000	2
核心四成分	1.000	1.000	4
全部主特征	1.000	1.000	10

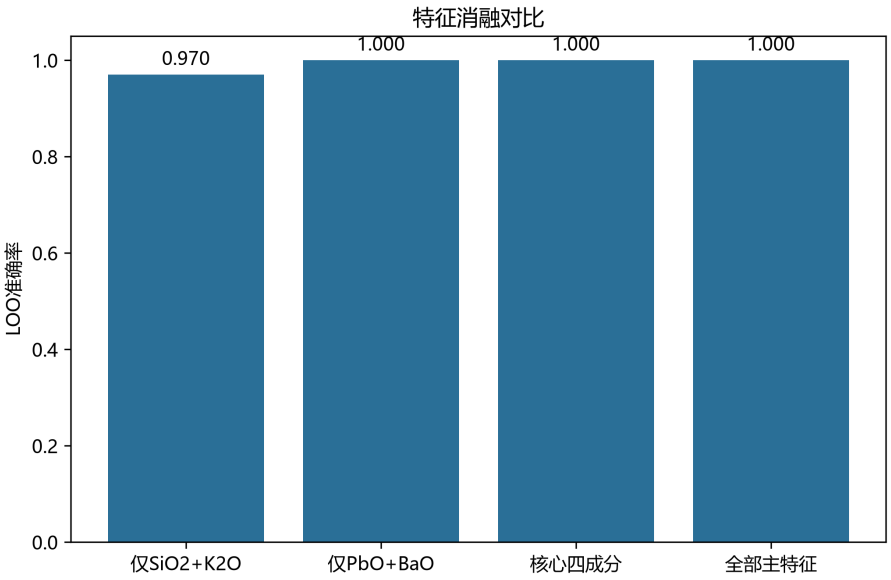


图 33 特征消融对比

风化分层准确率见表 15 与图 34，用于检查模型是否被风化状态系统性误导。

表 15 风化分层分类准确率

子集	n	准确率
全体	67	1.000
风化	32	1.000
无风化	35	1.000

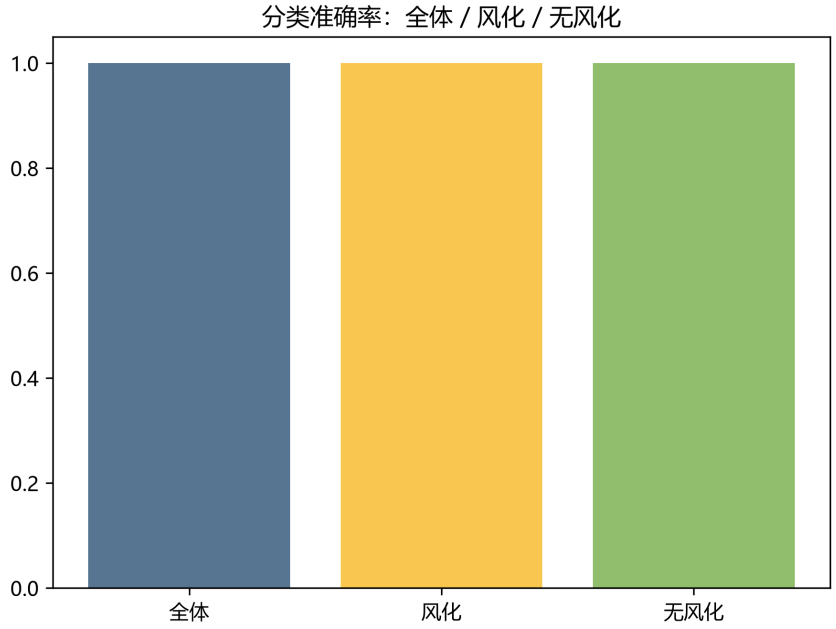


图 34 全体/风化/无风化准确率

9.2 鲁棒性（蒙特卡洛）

对训练成分施加相对噪声并反复预测，准确率分布见图 35：均值 1.0000，5%–95% 分位 [1.0000, 1.0000]，不低于 0.9 的概率 100.00%。

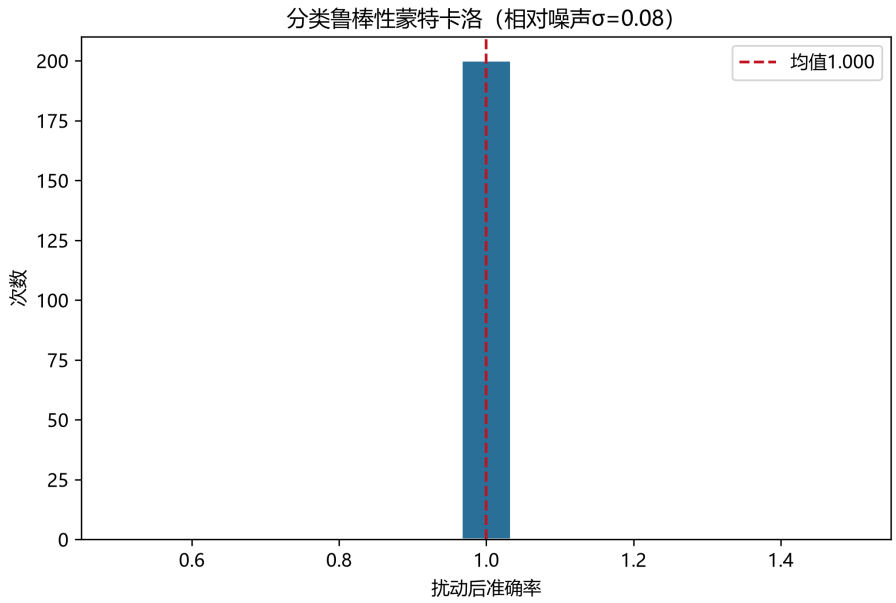


图 35 分类准确率蒙特卡洛分布

9.3 误差与局限

1. 风化因子基于组间均值，难以刻画同一文物不同部位的非线性风化；
2. 空白按 0 填充会压缩极低含量成分的变异；
3. 未知样本若处于两类重叠区，置信度与翻转率应同时解读；
4. 亚类数由轮廓系数选择，解释需结合考古工艺知识，不宜过度本体论化。

10 模型评价与推广

10.1 优点

形成了从风化机制到类型鉴别再到关联结构的统一框架；强调可解释规则与统计学习对照；检验覆盖灵敏度与鲁棒性。

10.2 创新点

1. 类型条件风化因子反演及与无校正/差值校正的定量对比；
2. 规则–学习双轨分类 + 特征消融，明确 Pb/Ba 主导与多特征增益；

3. 未知样本的概率、噪声翻转与训练留一稳定性三重证据；

4. Mantel 与 $|\Delta r|$ 排序的相关结构差异性检验；

5. 风化分层准确率与整体 MC 鲁棒性闭环。

10.3 推广

方法可推广至陶瓷胎釉成分甄别、金属器合金风化校正与产地溯源等“成分性数据 + 环境蚀变”问题。

11 参考文献

参考文献

[1] 全国大学生数学建模竞赛组委会. 2022 年高教社杯全国大学生数学建模竞赛题目 C 题 [Z]. 2022.

[2] Breiman L. Random forests[J]. Machine Learning, 2001, 45(1): 5-32.

[3] Cover T, Hart P. Nearest neighbor pattern classification[J]. IEEE Trans. Inf. Theory, 1967, 13(1): 21-27.

[4] Cortes C, Vapnik V. Support-vector networks[J]. Machine Learning, 1995, 20(3): 273-297.

[5] Spearman C. The proof and measurement of association between two things[J]. Am. J. Psychol., 1904, 15: 72-101.

[6] Mantel N. The detection of disease clustering and a generalized regression approach[J]. Cancer Res., 1967, 27(2): 209-220.

[7] Rousseeuw P J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis[J]. J. Comput. Appl. Math., 1987, 20: 53-65.

[8] Aitchison J. The Statistical Analysis of Compositional Data[M]. Chapman and Hall, 1986.

[9] Fisher R A. On the interpretation of χ^2 from contingency tables[J]. J. R. Stat. Soc., 1922, 85(1): 87-94.

[10] Mann H B, Whitney D R. On a test of whether one of two random variables is stochastically larger than the other[J]. Ann. Math. Stat., 1947, 18(1): 50-60.

A 附录：决策树规则文本

决策树（深度 3）导出的分割规则保存于配套文件 output/tables/q2_decision_tree_rules.txt，可用于考古场景的快速人工复核。

B 附录：核心代码说明

一键复现入口为 python run_all.py，依次执行：预处理与 EDA、Q1 风化分析、Q2 分类与亚类、Q3 未知鉴别、Q4 关联差异、高级检验、论文编译。代码位于 code/目录，以脚本方式通过 sys.path 导入工具模块，避免将项目包装为遮蔽标准库的 code 包。

C 附录：补充说明

1. 统计口径：含量为质量百分比；有效样本成分和 $\in [85\%, 105\%]$；风化预测输出已归一化。
2. 论文图表由运行脚本自动生成并嵌入，数值与 output/results_summary.md 及 CSV 一致。
3. 若需查看亚类中心坐标，参见 q2_subclass_centers_*.csv。

D 附录：实施效果与使用建议

在考古实验室场景中，可按如下流程落地：

1. 录入或导入 XRF/SEM-EDS 成分表，自动计算成分和并过滤无效行；
2. 若样本标注为风化，先按类型调用风化因子反演，得到风化前估计谱；
3. 用随机森林给出类型概率，同时输出化学规则标签作交叉核对；
4. 当置信度低于 0.8 或噪声翻转率高于 0.2 时，建议补测未风化点或增加检测点位；
5. 对已分类样本，定期更新 Spearman 网络，监控配方结构是否出现新亚型。

设判别器输出概率 $\hat{p}_i$，定义风险分数

$$\mathrm{Risk}_i = (1 - \mathrm{Conf}_i) + \lambda \cdot \mathrm{Flip}_i, \tag{14}$$

其中 $\lambda > 0$ 平衡置信度与扰动敏感性。该风险分数可用于实验排期：优先复测高风险样本，从而在有限检测预算下提升整体鉴别可靠度。

对亚类结果，建议与纹饰、颜色及出土地点做交叉表验证。若某一亚类在地理或纹饰上高度富集，则可解释为工艺传统差异；若完全随机，则提示聚类可能主要捕捉连续风化梯度，需要回到 Q1 校正后再划分。

E 附录：更多公式推导

E.1 风化因子的一阶误差传播

若观测存在相对误差 δ，即 $x'_{ic} = x_{ic}(1+\delta)$，则反演

$$\hat{x}^{(0)\prime}_{ic} = 100 \cdot \frac{x'_{ic}/f_{t,c}}{\sum_{c'} x'_{ic}/f_{t,c'}} = 100 \cdot \frac{x_{ic}/f_{t,c}}{\sum_{c'} x_{ic}/f_{t,c'}} = \hat{x}^{(0)}_{ic}. \tag{15}$$

说明：在全部成分同比例缩放时，归一化反演对全局倍率误差不敏感；真正影响结果的是**成分间相对比例**被风化扭曲的部分，这也是需要按类型估计 $f_{t,c}$ 的原因。

E.2 随机森林投票的置信度含义

对 B 棵树，

$$\mathrm{Conf}_i = \max_{y} \frac{1}{B} \sum_{b=1}^{B} \mathbf{1}(h_b(\mathbf{z}_i) = y). \tag{16}$$

当两类先验不均衡时，仍建议同时报告两类概率，而不是只报告 Conf_i，以免多数类偏向被误读为“高把握”。

E.3 Mantel 统计量

将上三角相关向量记为 $\mathrm{vec}_{\triangle}(R)$，则

$$r_{\mathrm{Mantel}} = \mathrm{Corr}\big(\mathrm{vec}_{\triangle}(R^{(\mathrm{HK})}), \mathrm{vec}_{\triangle}(R^{(\mathrm{PB})})\big), \tag{17}$$

再通过对其中一个矩阵的标签置换得到原假设分布，从而给出 p 值。该检验回答的是“两套相关结构是否相似”，与“某一对成分是否显著相关”是不同层级的问题。